

PRÁCTICA 2: SIMULACIÓN MCMC con JAGS

Introducción a la inferencia bayesiana basada en simulación

Nos planteamos de nuevo el modelo de regresión del banco de datos `cars` que trabajamos durante la práctica anterior.

1. Formula y simula dicho modelo de regresión, ahora con **JAGS**. Toma las acciones oportunas para que puedas dar por buena la convergencia de la simulación y representa las cadenas que hayas simulado.

```
library(jagsUI)
library(MCMCvis)

# Modelo de regresión lineal simple

cat(
  "model{
    for(i in 1:length(dist)){
      dist[i] ~ dnorm(beta0+beta1*velocidad[i],tau)
    }
    beta0 ~ dnorm(0,0.000001)
    beta1 ~ dnorm(0,0.000001)
    tau <- sd.error^-2
    sd.error ~ dunif(0,1000)
  }",file="RegLinSimple.jags")
```

```

# Ejecución del modelo
data = list(dist = cars$dist, velocidad = cars$speed)
inits = function(){list(beta0 = rnorm(1,mean(cars$dist),10),
                        beta1 = rnorm(1,mean(cars$dist),1),
                        sd.error = runif(1,0,10))}
param = c("beta0", "beta1", "sd.error")
set.seed(1)
resulcars <- jags(model.file = "RegLinSimple.jags", data = data, inits = inits,
                 parameters.to.save = param, n.chains = 3, n.iter = 5000,
                 n.burnin = 1000, n.thin = 4)


##
## Processing function input.....
##
## Done.
##
## Compiling model graph
##   Resolving undeclared variables
##   Allocating nodes
## Graph information:
##   Observed stochastic nodes: 50
##   Unobserved stochastic nodes: 3
##   Total graph size: 147
##
## Initializing model
##
## Adaptive phase.....
## Adaptive phase complete
##
##

```

```
## Burn-in phase, 1000 iterations x 3 chains
##
##
## Sampling from joint posterior, 4000 iterations x 3 chains
##
##
## Calculating statistics.....
##
## Done.
```

Monitorización de las cadenas simuladas

```
MCMCtrace(resulcars, pdf = FALSE, ind = TRUE)
```



Parece que el comportamiento de las cadenas es bastante satisfactorio

Nos proponemos ahora analizar el banco de datos `InsectSprays` de R. El banco de datos consta únicamente de 2 variables, `count` y `spray`. La primera variable corresponde al número de insectos muertos observados al aplicar cierto insecticida y la segunda sería el insecticida aplicado, que sería una variable categórica.

2. Formula, y simula, en JAGS el modelo de regresión que consideres oportuno para analizar el distinto efecto de cada uno de los insecticidas. Ten en cuenta que **spray** es una variable categórica, que JAGS no sabe como tratar, por lo que tendrás que convertirla a numérica y darle el tratamiento oportuno. No puedes (mejor dicho no debes) meterla en el modelo de la misma manera que en el modelo de regresión anterior como si fuera una variable numérica tal cual. Piensa cómo darle el carácter categórico que tiene esta variable.

El modelo adecuado para el análisis de este banco de datos es un modelo de regresión de Poisson. Para su programación en JAGS habremos de detallar todos los supuestos que corresponden a ese modelo, en particular los necesarios para modelizar los datos de los que disponemos. Como hemos comentado, el carácter categórico de **spray** requerirá cierto cuidado. Los modelos de regresión frecuentistas, al incluir una variable categórica con P categorías añaden $P - 1$ variables nuevas en el modelo, donde cada variable modeliza el efecto particular de cada grupo. Nosotros por analogía deberíamos hacer algo parecido. A continuación detallamos 2 modelos alternativos, pero equivalentes, de regresión de Poisson correspondientes al banco de datos **InsectSprays**.

```
cat(  
  "model{  
    for(i in 1:length(insectos)){  
      insectos[i] ~ dpois(efecto[i])  
      # beta corresponde al efecto de cada insecticida y insecti asigna cada  
      # observación al insecticida correspondiente  
      log(efecto[i]) <- inter + beta[insecticida[i]]  
    }  
    inter ~ dnorm(0,0.000001)  
    beta[1] <- 0  
    for(j in 2:nInsecti){  
      beta[j] ~ dnorm(0,0.000001)  
    }  
  }
```

```

}",file="RegPois1.jags")

cat(
  "model{
    for(i in 1:length(insectos)){
      insectos[i] ~ dpois(efecto[i])
      # las expresiones insecti[i] == j crean variables binarias que mapean cada
      # valor de la variable insecticida al efecto correspondiente
      log(efecto[i]) <- inter + beta[2] * (insecticida[i] == 2) +
        beta[3] * (insecticida[i] == 3) + beta[4] * (insecticida[i] == 4) +
        beta[5] * (insecticida[i] == 5) + beta[6] * (insecticida[i] == 6)
    }
    inter ~ dnorm(0,0.000001)
    beta[1] <- 0
    for(j in 2:nInsecti){
      beta[j] ~ dnorm(0,0.000001)
    }
  }",file="RegPois2.jags")

# Ejecución de los modelos
# insecticida se convierte a variable numérica, el único formato válido para JAGS
data = list(insectos = InsectSprays$count, nInsecti = 6,
            insecticida = as.numeric(InsectSprays$spray))
inits = function(){list(inter = rnorm(1), beta = c(NA, rnorm(5)))}
param = c("inter", "beta")
set.seed(1)
resulPois1 <- jags(model.file = "RegPois1.jags", data = data, inits = inits,
                  parameters.to.save = param, n.chains = 3, n.iter = 5000,
                  n.burnin = 1000, n.thin = 4)

```

```
##
## Processing function input.....
##
## Done.
##
## Compiling model graph
##   Resolving undeclared variables
##   Allocating nodes
## Graph information:
##   Observed stochastic nodes: 72
##   Unobserved stochastic nodes: 6
##   Total graph size: 165
##
## Initializing model
##
## Adaptive phase.....
## Adaptive phase complete
##
##
##   Burn-in phase, 1000 iterations x 3 chains
##
##
## Sampling from joint posterior, 4000 iterations x 3 chains
##
##
## Calculating statistics.....
##
## Done.
```

```

set.seed(2)
resulPois2 <- jags(model.file = "RegPois2.jags", data = data, inits = inits,
                  parameters.to.save = param, n.chains = 3, n.iter = 5000,
                  n.burnin = 1000, n.thin = 4)

##
## Processing function input.....
##
## Done.
##
## Compiling model graph
##   Resolving undeclared variables
##   Allocating nodes
## Graph information:
##   Observed stochastic nodes: 72
##   Unobserved stochastic nodes: 6
##   Total graph size: 210
##
## Initializing model
##
## Adaptive phase.....
## Adaptive phase complete
##
##
## Burn-in phase, 1000 iterations x 3 chains
##
##
## Sampling from joint posterior, 4000 iterations x 3 chains
##
##

```

```
## Calculating statistics.....
```

```
##
```

```
## Done.
```

```
# Estimación de los parámetros para ambos modelos
```

```
resulPois1
```

```
## JAGS output for model 'RegPois1.jags', generated by jagsUI.
```

```
## Estimates based on 3 chains of 5000 iterations,
```

```
## adaptation = 100 iterations (sufficient),
```

```
## burn-in = 1000 iterations and thin rate = 4,
```

```
## yielding 3000 total samples from the joint posterior.
```

```
## MCMC ran for 0.084 minutes at time 2025-05-04 11:10:55.000898.
```

```
##
```

##	mean	sd	2.5%	50%	97.5%	overlap0	f	Rhat	n.eff
## inter	2.669	0.076	2.523	2.673	2.816	FALSE	1.000	1.002	1189
## beta[1]	0.000	0.000	0.000	0.000	0.000	TRUE	1.000	NA	1
## beta[2]	0.056	0.104	-0.149	0.057	0.250	TRUE	0.703	1.001	3000
## beta[3]	-1.956	0.211	-2.393	-1.947	-1.565	FALSE	1.000	1.001	1741
## beta[4]	-1.094	0.153	-1.392	-1.091	-0.801	FALSE	1.000	1.003	928
## beta[5]	-1.430	0.177	-1.792	-1.426	-1.091	FALSE	1.000	1.001	1462
## beta[6]	0.140	0.106	-0.064	0.139	0.340	TRUE	0.907	1.002	782
## deviance	370.565	3.411	365.814	369.935	378.894	FALSE	1.000	1.000	3000

```
##
```

```
## **WARNING** Some Rhat values could not be calculated.
```

```
## Successful convergence based on Rhat values (all < 1.1).
```

```
## Rhat is the potential scale reduction factor (at convergence, Rhat=1).
```

```
## For each parameter, n.eff is a crude measure of effective sample size.
```

```
##
```

```
## overlap0 checks if 0 falls in the parameter's 95% credible interval.
```

```
## f is the proportion of the posterior with the same sign as the mean;
```



```

## i.e., our confidence that the parameter is positive or negative.
##
## DIC info: (pD = var(deviance)/2)
## pD = 5.8 and DIC = 376.385
## DIC is an estimate of expected predictive error (lower is better).

```

```

resulPois2

```

```

## JAGS output for model 'RegPois2.jags', generated by jagsUI.
## Estimates based on 3 chains of 5000 iterations,
## adaptation = 100 iterations (sufficient),
## burn-in = 1000 iterations and thin rate = 4,
## yielding 3000 total samples from the joint posterior.
## MCMC ran for 0.077 minutes at time 2025-05-04 11:11:00.097156.
##
##
##          mean    sd   2.5%   50%   97.5% overlap0    f  Rhat n.eff
## inter      2.671 0.077   2.518   2.672   2.816    FALSE 1.000 1.001 1751
## beta[1]     0.000 0.000   0.000   0.000   0.000     TRUE 1.000    NA     1
## beta[2]     0.059 0.106  -0.145   0.058   0.271     TRUE 0.706 1.001 3000
## beta[3]    -1.964 0.217  -2.413  -1.958  -1.565    FALSE 1.000 1.002   865
## beta[4]    -1.091 0.150  -1.395  -1.089  -0.796    FALSE 1.000 1.002 1098
## beta[5]    -1.435 0.171  -1.776  -1.435  -1.117    FALSE 1.000 1.000 3000
## beta[6]     0.136 0.104  -0.064   0.135   0.338     TRUE 0.904 1.003   522
## deviance 370.607 3.451 365.830 369.959 379.340    FALSE 1.000 1.003 3000
##
## **WARNING** Some Rhat values could not be calculated.
## Successful convergence based on Rhat values (all < 1.1).
## Rhat is the potential scale reduction factor (at convergence, Rhat=1).
## For each parameter, n.eff is a crude measure of effective sample size.
##
## overlap0 checks if 0 falls in the parameter's 95% credible interval.

```


```
## f is the proportion of the posterior with the same sign as the mean;
## i.e., our confidence that the parameter is positive or negative.
##
## DIC info: (pD = var(deviance)/2)
## pD = 6 and DIC = 376.564
## DIC is an estimate of expected predictive error (lower is better).
```


Los parámetros de convergencia son adecuados para ambos modelos

Las estimaciones de ambos modelos parecen compatibles

Monitorización de las cadenas simuladas para resulPois1

```
MCMCtrace(resulPois1, pdf = FALSE, ind = TRUE)
```





*# La visualización de las cadenas para resulPois1 resulta satisfactoria
tal y como anticipaban los estadísticos de convergencia. Algo similar
ocurriría con resulPois2*

3. Modifica el modelo propuesto de la manera que creas conveniente para estimar $P(\beta_i > 0)$, donde β_i , $2, \dots, 6$ es el efecto de cada grupo, y así poder estimar la “significatividad” (/relevancia estadística) del efecto de cada insecticida.

```
cat(
  "model{
    for(i in 1:length(insectos)){
      insectos[i] ~ dpois(efecto[i])

      # beta corresponde al afecto de cada insecticida y insecti asigna cada
      # observación al insecticida correspondiente
      log(efecto[i]) <- inter + beta[insecticida[i]]
    }

    inter ~ dnorm(0,0.000001)

    beta[1] <- 0

    for(j in 2:nInsecti){
      beta[j] ~ dnorm(0,0.000001)
      Pbeta[j] <- beta[j] > 0
    }
  }",file="RegPois1plus.jags")

param = c("inter", "beta","Pbeta")
```

```

set.seed(1)
resulPois1plus <- jags(model.file = "RegPois1plus.jags", data = data, inits = inits,
                      parameters.to.save = param, n.chains = 3, n.iter = 5000,
                      n.burnin = 1000, n.thin = 4)

##
## Processing function input.....
##
## Done.
##
## Compiling model graph
##   Resolving undeclared variables
##   Allocating nodes
## Graph information:
##   Observed stochastic nodes: 72
##   Unobserved stochastic nodes: 6
##   Total graph size: 170
##
## Initializing model
##
## Adaptive phase.....
## Adaptive phase complete
##
##
## Burn-in phase, 1000 iterations x 3 chains
##
##
## Sampling from joint posterior, 4000 iterations x 3 chains
##
##

```

```
## Calculating statistics.....
```

```
##
```

```
## Done.
```

```
resulPois1plus
```

```
## JAGS output for model 'RegPois1plus.jags', generated by jagsUI.
```

```
## Estimates based on 3 chains of 5000 iterations,
```

```
## adaptation = 100 iterations (sufficient),
```

```
## burn-in = 1000 iterations and thin rate = 4,
```

```
## yielding 3000 total samples from the joint posterior.
```

```
## MCMC ran for 0.084 minutes at time 2025-05-04 11:11:11.982759.
```

```
##
```

##	mean	sd	2.5%	50%	97.5%	overlap0	f	Rhat	n.eff
## inter	2.669	0.076	2.523	2.673	2.816	FALSE	1.000	1.002	1189
## beta[1]	0.000	0.000	0.000	0.000	0.000	TRUE	1.000	NA	1
## beta[2]	0.056	0.104	-0.149	0.057	0.250	TRUE	0.703	1.001	3000
## beta[3]	-1.956	0.211	-2.393	-1.947	-1.565	FALSE	1.000	1.001	1741
## beta[4]	-1.094	0.153	-1.392	-1.091	-0.801	FALSE	1.000	1.003	928
## beta[5]	-1.430	0.177	-1.792	-1.426	-1.091	FALSE	1.000	1.001	1462
## beta[6]	0.140	0.106	-0.064	0.139	0.340	TRUE	0.907	1.002	782
## Pbeta[2]	0.703	0.457	0.000	1.000	1.000	TRUE	1.000	1.000	3000
## Pbeta[3]	0.000	0.000	0.000	0.000	0.000	TRUE	1.000	NA	1
## Pbeta[4]	0.000	0.000	0.000	0.000	0.000	TRUE	1.000	NA	1
## Pbeta[5]	0.000	0.000	0.000	0.000	0.000	TRUE	1.000	NA	1
## Pbeta[6]	0.907	0.290	0.000	1.000	1.000	TRUE	1.000	1.002	2825
## deviance	370.565	3.411	365.814	369.935	378.894	FALSE	1.000	1.000	3000

```
##
```

```
## **WARNING** Some Rhat values could not be calculated.
```

```
## Successful convergence based on Rhat values (all < 1.1).
```

```
## Rhat is the potential scale reduction factor (at convergence, Rhat=1).
```

```
## For each parameter, n.eff is a crude measure of effective sample size.
##
## overlap0 checks if 0 falls in the parameter's 95% credible interval.
## f is the proportion of the posterior with the same sign as the mean;
## i.e., our confidence that the parameter is positive or negative.
##
## DIC info: (pD = var(deviance)/2)
## pD = 5.8 and DIC = 376.385
## DIC is an estimate of expected predictive error (lower is better).

# Encontramos que los insecticidas 3, 4 y 5 tienen una muy baja probabilidad
# de tener un efecto superior al insecticida 1, por tanto tenemos evidencia
# de un efecto inferior, pero al fin y al cabo distinto al grupo 1. No pasa
# lo mismo con los insecticidas 2 y 6.
```

El banco de datos **esoph** de **R** contiene información de un estudio casos-control sobre el cáncer de esófago. Concretamente, estamos interesados en estudiar cómo varía la probabilidad de desarrollar dicho cáncer en función de la edad y el consumo de alcohol y tabaco. Para ello haremos uso de las siguientes variables del banco de datos:

- **agecp**: variable categórica que resume la edad de cada uno de los participantes, con 6 valores: 25-34, 35-44, 45-54, 55-64, 65-74, 75+
- **alcgp**: variable categórica que resume el consumo diario de alcohol de cada uno de los participantes, con 4 valores: 0-39 gramos día, 40-79, 80-119, 120+.
- **tobgp**: variable categórica que resume el consumo diario de tabaco de cada uno de los participantes, con 4 valores: 0-9g/day, 10-19, 20-29, 30+.
- **ncases**: número de casos observados para cada grupo del estudio.
- **ncontrols**: número de controles (no casos) para cada grupo del estudio.

4. Estudia, haciendo uso de **JAGS**, cómo modifica cada uno de los factores considerados la probabilidad de desarrollar cáncer de esófago.

```

cat(
  "model{
    for(i in 1:length(ncasos)){
      ncasos[i] ~ dbin(p[i],ntot[i])
      logit(p[i]) <- inter + beta.edad[edad[i]] + beta.alc[alc[i]] +
        beta.tab[tab[i]]
    }
    inter ~ dnorm(0,0.000001)
    beta.edad[1] <- 0; beta.alc[1] <- 0; beta.tab[1] <- 0
    for(j in 2:6){
      beta.edad[j] ~ dnorm(0,0.000001)
      Pbeta.edad[j] <- beta.edad[j] > 0
    }
    for(j in 2:4){
      beta.alc[j] ~ dnorm(0,0.000001)
      Pbeta.alc[j] <- beta.alc[j] > 0
    }
    for(j in 2:4){
      beta.tab[j] ~ dnorm(0,0.000001)
      Pbeta.tab[j] <- beta.tab[j] > 0
    }
  }",file="RegLogis.jags")

data = list(ncasos = esoph$ncases, ntot = esoph$ncases+esoph$ncontrols,
            edad = as.numeric(esoph$agegp), alc = as.numeric(esoph$alcgp),
            tab = as.numeric(esoph$tobgp))
inits = function(){list(inter = rnorm(1), beta.edad = c(NA, rnorm(5)),
                        beta.alc = c(NA, rnorm(3)), beta.tab = c(NA, rnorm(3)))}
param = c("inter", "beta.edad", "Pbeta.edad", "beta.alc", "Pbeta.alc", "beta.tab",

```

```

        "Pbeta.tab")
set.seed(1)
resulLogis <- jags(model.file = "RegLogis.jags", data = data, inits = inits,
                  parameters.to.save = param, n.chains = 3, n.iter = 5000,
                  n.burnin = 1000, n.thin = 4)

##
## Processing function input.....
##
## Done.
##
## Compiling model graph
##   Resolving undeclared variables
##   Allocating nodes
## Graph information:
##   Observed stochastic nodes: 88
##   Unobserved stochastic nodes: 12
##   Total graph size: 641
##
## Initializing model
##
## Adaptive phase.....
## Adaptive phase complete
##
##
## Burn-in phase, 1000 iterations x 3 chains
##
##
## Sampling from joint posterior, 4000 iterations x 3 chains
##

```



```
##
## Calculating statistics.....
##
## Done.
```

resulLogis

```
## JAGS output for model 'RegLogis.jags', generated by jagsUI.
## Estimates based on 3 chains of 5000 iterations,
## adaptation = 100 iterations (sufficient),
## burn-in = 1000 iterations and thin rate = 4,
## yielding 3000 total samples from the joint posterior.
## MCMC ran for 0.132 minutes at time 2025-05-04 11:11:17.170643.
```

```
##
##          mean    sd    2.5%    50%    97.5% overlap0      f  Rhat n.eff
## inter          -7.378 1.053   -9.687   -7.287   -5.588    FALSE 1.000 1.047    85
## beta.edad[1]      0.000 0.000    0.000    0.000    0.000     TRUE 1.000    NA     1
## beta.edad[2]      2.344 1.097    0.408    2.221    4.786    FALSE 0.992 1.049    77
## beta.edad[3]      4.190 1.054    2.418    4.081    6.584    FALSE 1.000 1.046    82
## beta.edad[4]      4.755 1.048    2.960    4.641    7.099    FALSE 1.000 1.047    80
## beta.edad[5]      5.340 1.055    3.533    5.225    7.680    FALSE 1.000 1.049    79
## beta.edad[6]      5.259 1.101    3.373    5.149    7.678    FALSE 1.000 1.036   105
## Pbeta.edad[2]     0.992 0.091    1.000    1.000    1.000    FALSE 1.000 1.142   344
## Pbeta.edad[3]     1.000 0.000    1.000    1.000    1.000    FALSE 1.000    NA     1
## Pbeta.edad[4]     1.000 0.000    1.000    1.000    1.000    FALSE 1.000    NA     1
## Pbeta.edad[5]     1.000 0.000    1.000    1.000    1.000    FALSE 1.000    NA     1
## Pbeta.edad[6]     1.000 0.000    1.000    1.000    1.000    FALSE 1.000    NA     1
## beta.alc[1]        0.000 0.000    0.000    0.000    0.000     TRUE 1.000    NA     1
## beta.alc[2]        1.467 0.248    0.985    1.459    1.949    FALSE 1.000 1.004  1002
## beta.alc[3]        2.025 0.279    1.510    2.021    2.578    FALSE 1.000 1.004   519
## beta.alc[4]        3.689 0.387    2.932    3.673    4.451    FALSE 1.000 1.004   574
```

```

## Pbeta.alc[2]      1.000 0.000   1.000   1.000   1.000   FALSE 1.000   NA     1
## Pbeta.alc[3]      1.000 0.000   1.000   1.000   1.000   FALSE 1.000   NA     1
## Pbeta.alc[4]      1.000 0.000   1.000   1.000   1.000   FALSE 1.000   NA     1
## beta.tab[1]       0.000 0.000   0.000   0.000   0.000    TRUE 1.000   NA     1
## beta.tab[2]       0.444 0.227  -0.005   0.440   0.899    TRUE 0.973 1.007  279
## beta.tab[3]       0.525 0.278  -0.020   0.528   1.070    TRUE 0.970 1.003  748
## beta.tab[4]       1.670 0.343   0.996   1.667   2.324   FALSE 1.000 1.000 3000
## Pbeta.tab[2]      0.973 0.161   0.000   1.000   1.000    TRUE 1.000 1.006 3000
## Pbeta.tab[3]      0.970 0.170   0.000   1.000   1.000    TRUE 1.000 1.003 3000
## Pbeta.tab[4]      1.000 0.000   1.000   1.000   1.000   FALSE 1.000   NA     1
## deviance          209.121 4.603 201.689 208.638 219.524   FALSE 1.000 1.005  524
##
## **WARNING** Some Rhat values could not be calculated.
## **WARNING** Rhat values indicate convergence failure.
## Rhat is the potential scale reduction factor (at convergence, Rhat=1).
## For each parameter, n.eff is a crude measure of effective sample size.
##
## overlap0 checks if 0 falls in the parameter's 95% credible interval.
## f is the proportion of the posterior with the same sign as the mean;
## i.e., our confidence that the parameter is positive or negative.
##
## DIC info: (pD = var(deviance)/2)
## pD = 10.6 and DIC = 219.682
## DIC is an estimate of expected predictive error (lower is better).

# La convergencia parece satisfactoria.
# Todos los valores no basales de cada una de las variables analizadas parecen
# mostrar un efecto significativo, o casi significativo en el caso del tabaco.

```