

Motivación e introducción a las técnicas de simulación MCMC

Introducción a la inferencia bayesiana basada en simulación

Miguel Ángel Martínez Beneito
miguel.a.martinez@uv.es



Sección 1

Inferencia bayesiana analítica

Inferencia bayesiana analítica

- La **inferencia bayesiana**, dado un modelo estadístico, **actualiza la información** inicial que pudiéramos tener sobre sus parámetros con la información proporcionada por los **datos**.
- El mecanismo que lleva a cabo esa actualización es el **Teorema de Bayes**:

$$P(\theta \mid \mathbf{x}) = \frac{P(\mathbf{x}|\theta)P(\theta)}{P(\mathbf{x})} \propto P(\mathbf{x}|\theta)P(\theta)$$

- Como resultado se obtiene la distribución a **posteriori** ($P(\theta \mid \mathbf{x})$) de los parámetros **a partir de** la función de **verosimilitud** ($P(\mathbf{x}|\theta) = L(\theta)$) y su **distribución inicial** ($P(\theta)$).

Ejemplo

- Queremos estimar el **porcentaje** de personas enfermas de **COVID** en cierta región.

Ejemplo

- Tomamos una **muestra** aleatoria de la población de **50 personas** en la que se observan **3 infectados**.

$$x \mid \pi \sim \text{binomial}(\pi, 50)$$

$$P(x = 3 \mid \pi) \propto \pi^3(1 - \pi)^{47}$$

- Queremos usar como **información inicial** que en otra oleada anterior de **20 pruebas** se observaron **2 positivos**.


$$\pi \sim \text{beta}(2, 18)$$

$$P(\pi) \propto \pi^{2-1}(1 - \pi)^{18-1}$$

- Aplicando el **teorema de Bayes** tenemos:

$$P(\pi \mid x = 3) \propto P(x = 3 \mid \pi)P(\pi) \propto \pi^{5-1}(1 - \pi)^{65-1}$$

$$\pi \mid x \sim \text{beta}(5, 65)$$



- El **mecanismo** de aprendizaje bayesiano es, en principio, **sencillo e intuitivo**.
- Desgraciadamente, basta con utilizar distribuciones iniciales **no conjugadas** para que **todo se complique** con facilidad.

Ejemplo (Colesterol)

- Se pretende estimar el valor medio de **colesterol** en sangre en cierta población, y disponemos de una **muestra** de valores $\{x_1, \dots, x_n\}$.
- Dichos valores se distribuyen según una **distribución Normal** alrededor de su media (μ) y con precisión s^{-2} (conocida).

$$\begin{aligned} L(\mu) &= P(\{x_1, \dots, x_n\} \mid \mu, s^{-2}) = \prod_{i=1}^n P(x_i \mid \mu, s^{-2}) = \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi s^2}} \exp\left(\frac{-(x_i - \mu)^2}{2s^2}\right) = \dots \propto \exp\left(\frac{-(\mu - \bar{x})^2}{2s^2/n}\right) \end{aligned}$$

- Conocemos por distintos estudios que el valor de μ en otras poblaciones toma valores **en torno a 100 y con varianza 20²**.
- Queríamos **incorporar dicha información** a nuestra estudio, pero **evitar** que la distribución inicial sea **demasiado influyente**.

- Decidimos asumir una **distribución t** (con colas muy pesadas) como previa para μ :

$$\mu \sim t_1(\mu \mid 100, 20^2) \propto \left(1 + \frac{(\mu - 100)^2}{20^2}\right)^{-1}$$

- Aplicando el **teorema de Bayes**:

$$P(\mu \mid \mathbf{x}) = \frac{P(\mathbf{x} \mid \mu)P(\mu)}{P(\mathbf{x})} = \frac{\exp\left(\frac{-(\mu - \bar{x})^2}{2s^2/n}\right) \left(1 + \frac{(\mu - 100)^2}{20^2}\right)^{-1}}{P(\mathbf{x})}$$

donde

$$P(\mathbf{x}) = \int_{-\infty}^{\infty} \exp\left(\frac{-(\mu - \bar{x})^2}{2s^2/n}\right) \left(1 + \frac{(\mu - 100)^2}{20^2}\right)^{-1} d\mu = ???$$

- Por tanto, el cálculo de $P(\mu \mid \mathbf{x})$ requiere el **cálculo** de una integral “**poco amigable**”.

- El uso de distribuciones **no conjugadas** conlleva el cálculo analítico de **integrales** para obtener el término $P(\mathbf{x})$ del teorema de Bayes.
- La sustitución del cálculo de dicha integral por algún **procedimiento numérico** computacionalmente manejable sería de **gran utilidad**.
- Paralelamente, todo se puede **complicar**, incluso utilizando distribuciones **iniciales conjugadas**. Basta con plantearnos inferencia bayesiana en **modelos multiparamétricos** para que los cálculos analíticos se compliquen con facilidad.
- Resulta muy conveniente disponer de un mecanismo de **inferencia paralelo** que **obvie las dificultades** numéricas que presentan los modelos bayesianos, salvo aquellos extremadamente simples.

Sección 2

Inferencia bayesiana basada en simulación

Motivación a la inferencia basada en simulación

- La **simulación** de muestras aleatorias supone una útil herramienta para la **inferencia** cuando el **abordaje analítico** resulta **demasiado complejo**.

Ejemplo

- Un conocido, **director de un hospital** nos plantea la siguiente cuestión:
 - El número diario de **altas hospitalarias** se distribuye según $A \sim \text{Bi}(a \mid 0.17, n)$, donde n es el número de pacientes ingresados en el hospital.
 - El número medio diario de **ingresos hospitalarios** sigue una distribución de Poisson de media 50, i. e. $I \sim \text{Po}(i \mid 50)$.
- Actualmente, el hospital tiene **todas sus plazas** ($n=300$) **ocupadas** y se nos plantea si mañana **serán capaces de atender todas las demandas** de ingreso, es decir, se quiere conocer la probabilidad de que el número de altas sea superior al número de ingresos.

Ejemplo

- Si A denota el número de altas y I el número de ingresos el día siguiente, deberíamos **calcular**:

$$P(A \geq I) = \sum_{a=0}^{\infty} \sum_{i=0}^a \pi(i, a) = \sum_{a=0}^{\infty} \text{Bi}(a|0.17, 300) \left(\sum_{i=0}^a \text{Po}(i|50) \right)$$

- Esta suma **no tiene forma analítica**, por tanto $P(A \geq I)$ tampoco la tiene.
- Así, $P(A \geq I)$ **sólo** puede ser calculado **numéricamente**, por ejemplo con R.
- Alternativamente**, podríamos aproximar $P(A \geq I)$, fácilmente, **mediante simulación**:

```
set.seed(1)
A <- rbinom(10000, prob = 0.17, size = 300)  #Altas
I <- rpois(10000, 50)  #Ingresos
sum(A >= I)/10000
## [1] 0.5627
```

- En general, la **simulación** es una **estrategia** que deberíamos tener en cuenta cuando la **aproximación analítica** resulta **problemática**, también desde una perspectiva bayesiana.

Inferencia basada en simulación:

- En general, si $\theta \sim \pi(\theta)$, para una función genérica $h(\cdot)$ queremos estimar:

$$E_{\pi}[h(\theta)] = \int_{\Omega} h(\theta)\pi(\theta)d\theta \quad (1)$$

- Esta expresión incluye, como casos particulares, **todos los momentos** (media, varianza ...) de θ .
- También $h(\theta)$ podría ser una **función de verosimilitud** (y $\pi(\theta)$ la distribución inicial de un parámetro θ), en cuyo caso la expresión (1) proporciona el **denominador** del **teorema de Bayes**.
- En general, la expresión (1) será **difícil** (o imposible) de calcular **analíticamente**.

- Los *métodos de integración de Monte Carlo* buscan **aproximar** la expresión (1) **mediante muestras** aleatorias de θ .
- El **principio** de los métodos de integración de **Monte Carlo** para aproximar (1) es el siguiente:
 - Generar una muestra $\boldsymbol{\theta} = \{\theta^{(1)}, \dots, \theta^{(M)}\}$ de $\pi(\theta)$.
 - Aproximar (1) por $\overline{h_M(\boldsymbol{\theta})} = M^{-1} \sum_{m=1}^M h(\theta^{(m)})$.
- Este resultado es consecuencia directa de la **Ley Fuerte de los Grandes Números**¹.
- Además, asintóticamente, según el **Teorema Central del Límite**:

$$\overline{h_M(\boldsymbol{\theta})} \sim N(E_\pi[h(\theta)], \text{Var}(h(\theta))/M).$$

Así, $\overline{h_M(\boldsymbol{\theta})}$ es **insesgado**, y podemos aproximar $E_\pi[h(\theta)]$ con la **precisión deseada**, simplemente **incrementando el tamaño muestral** de $\boldsymbol{\theta}$.

¹*Ley fuerte de los grandes números:* Si $X_1, X_2, \dots$ es una muestra de valores aleatorios i.i.d. con $E(X_i) = \mu$, entonces $\lim_{n \rightarrow \infty} \bar{X}_n = \mu$

Ejemplo

- Volviendo al estudio de las **altas e ingresos** hospitalarios, queríamos estimar:

$$P(A \geq I) = \sum_{a=0}^{\infty} \sum_{i=0}^a \pi(i, a) = \sum_{(i,a) \in \Omega} \delta(a \geq i) \pi(i, a)$$

- De acuerdo con el método de integración (suma en este caso) de Monte Carlo esta última expresión **puede ser aproximada** por

$$M^{-1} \sum_{m=1}^M \delta(a^{(m)} \geq i^{(m)})$$

para una muestra $\{(i^{(1)}, a^{(1)}), \dots, (i^{(M)}, a^{(M)})\}$ de $\pi(i, a)$.

- Este mismo proceso es el que **aplicamos**, de manera intuitiva, en el **ejemplo anterior**.

Ejemplo

- Se podrían llevar a cabo **procedimientos similares** para estimar **otros parámetros** de interés:

- $E(I) \approx M^{-1} \sum_{m=1}^M i^{(m)} = \bar{i}$

```
mean(I)
```

```
## [1] 50.1087
```

- $Var(A) = E((A - E(A))^2) \approx M^{-1} \sum_{m=1}^M (a^{(m)} - \bar{a})^2 = Var(\mathbf{a})$

```
var(A)
```

```
## [1] 42.61239
```



- En general, **aproximaremos** cada cantidad de interés de una variable mediante el **estadístico muestral correspondiente** de la muestra (*método de los momentos*).
 - Media poblacional $\rightarrow$ media muestral
 - Varianza poblacional $\rightarrow$ varianza muestral
 - $P(0 < X < 0.5) \rightarrow$ proporción de veces que $0 < X_i < 0.5$ en $X_1, X_2, \dots$
 - ...

Sección 3

Markov chain Monte Carlo

Simulación de Monte Carlo mediante cadenas de Markov

- Al hacer inferencia bayesiana nos encontramos en la **siguiente situación**:
 - Querremos muestrear de la distribución a posteriori** de una o varias variables.
 - La distribución a posteriori se conoce sólo parcialmente, se conoce su forma pero **no su constante de integración**.



- En caso de poder simular una **muestra** como la de la derecha nos permitiría **hacer inferencia** sobre el(/los) parámetro(s) deseado(s).

- Lamentablemente, las **distribuciones** de las que queremos muestrear serán **enrevesadas** y **problemáticas** para simular **valores independientes** de ellas.

Cadenas de Markov:

- Una *cadena de Markov* es una **secuencia** ordenada de variables aleatorias $\{x_1, x_2, \dots\}$ en los que cada valor, **condicionado a los anteriores**, depende **sólo** de la observación anterior. Es decir:

$$P(x_{i+1} \mid x_1, \dots, x_i) = P(x_{i+1} \mid x_i)$$

- El **futuro depende del pasado** sólo a través del **presente**.
- Se dice *distribución estacionaria* de una cadena de Markov la **distribución** que se reproduce al **simular indefinidamente** valores de la cadena.
- Una cadena de Markov **no es la muestra aleatoria que nos gustaría tener** de la correspondiente distribución estacionaria (son valores dependientes), pero **podría suplir** el uso de muestras independientes.

Métodos de Monte Carlo basados en cadenas de Markov:

- Los *métodos de Monte Carlo basados en cadenas de Markov* (**MCMC** por sus siglas en inglés) son métodos basados en **simulación** en los que la **muestra** de valores generados es una **cadena de Markov**.
- El principal uso de las técnicas **MCMC** es la generación de **muestras** (markovianas) cuya distribución estacionaria coincide con la distribución **a posteriori** que queremos conocer (aunque desconozcamos su constante de proporcionalidad).
- **Objetivo:** simular una **cadena de Markov** $\{\theta^{(1)}, \theta^{(2)}, \dots\}$ con **distribución estacionaria** $P(\theta \mid \mathbf{x})$, la **distribución a posteriori** de cierto modelo bayesiano.
- **Algoritmo** general:
 - Partimos de un **valor arbitrario** $\theta^{(0)}$.
 - Asumimos una **distribución** $q(\cdot \mid \cdot)$ que permite simular $\theta^{(i+1)} \mid \theta^{(i)} \sim q(\theta^{(i+1)} \mid \theta^{(i)})$ con **distribución estacionaria** $P(\theta \mid \mathbf{x})$.
 - **Simulamos** una **cadena de Markov** de la distribución anterior.

Metropolis Hastings

- Es, junto a Gibbs Sampling, **el principal algoritmo** MCMC para el muestreo de distribuciones a posteriori.
- Se trata de un **algoritmo de aceptación/rechazo**.

Algoritmo de simulación de Metropolis-Hastings:

- 1 **Dado un valor $\theta^{(i)}$** de la cadena de Markov, **simulamos otro valor $\theta^{(*)}$** de una distribución $q(\theta^{(*)} | \theta^{(i)})$ que nos sea conveniente
- 2 Calculamos la **probabilidad de aceptación** de $\theta^{(*)}$:

$$\alpha(\theta^{(*)}, \theta^{(i)}) = \min \left(1, \frac{P(\theta^{(*)} | \mathbf{x}) q(\theta^{(i)} | \theta^{(*)})}{P(\theta^{(i)} | \mathbf{x}) q(\theta^{(*)} | \theta^{(i)})} \right)$$

- 3 Consideramos $\theta^{(i+1)} = \begin{cases} \theta^{(*)} & \text{con probabilidad } \alpha \\ \theta^{(i)} & \text{con probabilidad } 1 - \alpha \end{cases}$
- 4 **Iterar** este procedimiento a conveniencia.

- Al tener α dos posteriors $P(\theta^{(*)} | \mathbf{x})$ y $P(\theta^{(i)} | \mathbf{x})$, en el numerador y el denominador, **no necesitamos su constante de integración** ya que cancelará.
- Este detalle es el que hace **útil** el algoritmo para **inferencia bayesiana**.
- **Cualquier distribución** $q(\cdot | \cdot)$ es **válida** para el algoritmo, pero una **elección adecuada** hará que la cadena de Markov muestre **mejores propiedades** (mayor independencia).
- Un caso particularmente popular consiste en utilizar distribuciones **simétricas** para $q(\cdot | \cdot)$, es decir:

$$q(\theta^{(*)} | \theta^{(i)}) = q(\theta^{(i)} | \theta^{(*)}).$$

en ese caso el **cociente** del algoritmo se **simplifica**.

- De entre las propuestas simétricas, resulta particularmente **popular las caminatas aleatorias**, en las que las funciones de propuesta (simétricas) son del tipo:

$$q(\theta^{(*)} | \theta^{(i)}) = N(\theta^{(*)} | \theta^{(i)}, \tau^2),$$

o

$$q(\theta^{(*)} | \theta^{(i)}) = U(\theta^{(*)} | \theta^{(i)} - \delta, \theta^{(i)} + \delta).$$

donde τ^2 y δ serán 2 **parámetros a sintonizar** y que influirán en la calidad final de la simulación.

Ejemplo (Colesterol)

- Volviendo al ejemplo del **colesterol**. La **distribución a posteriori**, salvo constante de integración, era:

$$P(\mu | \mathbf{x}) \propto \exp\left(-\frac{(\mu - \bar{\mathbf{x}})^2}{2s^2/n}\right) \left(1 + \frac{(\mu - 100)^2}{20^2}\right)^{-1}$$

Ejemplo


- Programamos un algoritmo de **Metropolis-Hastings de caminata aleatoria** para muestrear de $\mu \mid \mathbf{x}$, con función de propuesta $q(\cdot \mid \cdot)$ **normal** de varianza 2^2 .

```
xbar <- 112.9
s2 <- 214.6
n <- 9
posterior <- function(mu) {
  exp(-((mu - xbar)^2)/(2 * s2/n)) * (1 + ((mu - 100)^2)/(20^2))^-1
}

muestra <- vector(length = 1000)
mu <- 100
set.seed(1)
```

Ejemplo

```
for (i in 1:1000) {  
  munuevo <- rnorm(1, mu, 2)  
  alfa <- min(1, posterior(munuevo)/posterior(mu))  
  acepta <- rbinom(1, 1, alfa)  
  if (acepta == 1) {  
    mu <- munuevo  
  }  
  muestra[i] <- mu  
}
```



- La cadena generada muestra **dependencia**, pero nos permite **hacer inferencia** sobre μ .

Gibbs sampling

- El **problema de MH** es que si θ es **multidimensional**, encontrar una **función de propuesta** $q(\cdot | \cdot)$ razonable puede ser muy **complejo**.
- En ese caso, puede ser mucho mejor **muestrear, uno a uno**, los parámetros de θ .
- Muestreo de *Gibbs Sampling* para $P(\theta = (\theta_1, \dots, \theta_d) | \mathbf{x})$:
 - **Inicializar** $\theta^{(0)} = (\theta_1^{(0)}, \dots, \theta_d^{(0)})$;
 - Para $i = 1, \dots, n$.simulaciones:
 - **Simular** $\theta_1^{(i)}$ de la distribución **condicional** $\theta_1 | (\theta_2^{(i-1)}, \dots, \theta_d^{(i-1)}, \mathbf{x})$;
 - **Simular** $\theta_2^{(i)}$ de la distribución **condicional** $\theta_2 | (\theta_1^{(i)}, \theta_3^{(i-1)}, \dots, \theta_d^{(i-1)}, \mathbf{x})$;
 - ...
 - **Simular** $\theta_d^{(i)}$ de la distribución **condicional** $\theta_d | (\theta_1^{(i)}, \dots, \theta_{d-1}^{(i)}, \mathbf{x})$;
 - **Guardar** $\theta^{(i)} = (\theta_1^{(i)}, \dots, \theta_d^{(i)})$ como elemento i -ésimo de la muestra a posteriori de $P(\theta | \mathbf{x})$.

- Habitualmente, $\theta_j \mid \theta_1, \dots, \theta_{j-1}, \theta_{j+1}, \dots, \theta_d, \mathbf{x}$ suele ser **fácil de muestrear**, con alguna función de R.
- **Cuando no lo sea**, podremos emplear un algoritmo **MH** univariante para muestrear ese parámetro.

Ejemplo

- Volviendo al ejemplo del **colesterol** nos planteamos ahora **modelizar** los datos de la siguiente manera^a:

$$X_i \sim N(\mu, \tau), \quad i = 1, \dots, I$$

$$\mu \sim N(m, t), \quad \tau \sim \text{Gamma}(a, b)$$

con distribuciones iniciales **poco informativas**, por ejemplo con:
 $m = 0, t = 10^{-6}, a = 0.001, b = 0.001$.

- Querremos muestrear mediante **Gibbs Sampling** de la distribución conjunta de μ, τ .

^aLas distribuciones normales en el modelo se han parametrizado en función de su precisión

Ejemplo

- Función de **verosimilitud**:

$$L(\mu, \tau) = \prod_{i=1}^n P(x_i | \mu, \tau) \propto \tau^{n/2} \exp\left(\frac{-\tau \sum_{i=1}^n (X_i - \mu)^2}{2}\right)$$

- Distribución a **posteriori**:

$$P(\mu, \tau | \mathbf{x}) \propto \left(\tau^{n/2} \exp\left(\frac{-\tau \sum (X_i - \mu)^2}{2}\right) \right) \cdot \left(\exp\left(\frac{-t(\mu - m)^2}{2}\right) \right) \cdot (\tau^{a-1} \exp(-b\tau))$$

- Distribuciones **condicionales a posteriori**:

$$P(\mu | \mathbf{x}, \tau) \sim N\left(\frac{\tau \sum x_i + t \cdot m}{\tau \cdot n + t}, \tau \cdot n + t\right)$$

$$P(\tau | \mathbf{x}, \mu) \sim \text{Gamma}\left(a + \frac{n}{2}, b + \frac{\sum (x_i - \mu)^2}{2}\right)$$

Ejemplo

- **Algoritmo de Gibbs** para el muestreo de $P(\mu, \tau \mid \mathbf{x})$:

```
x = c(106, 115, ...) # Datos: valores de colesterol
n = length(x) # n=9
m = 0; t = 1e-6; a = 0.001; b = 0.001 #hiperparámetros
mu = 100; tau = 1 # mu_0, tau_0
muestra <- matrix(nrow = 1000, ncol = 2)
for(i in 1:1000){
  # Muestreo de tau
  tau = rgamma(1, a + n/2, b + sum((x-mu)^2)/2)
  # Muestreo de mu
  mu = rnorm(1, (tau * sum(x) + t*m)/(tau * n + t),
            tau * n + t)
  muestra[i,] = c(mu, tau)
}
```


- Con este código **dispondremos de muestras** de $P(\mu, \tau \mid \mathbf{x})$ que podremos utilizar a **nuestra conveniencia**.

Ejemplo

```
summary(mu)  # Estadísticos de  $P(\mu/x)$ 
```

##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	112.7	112.9	112.9	112.9	112.9	113.1

```
par(mfrow = c(1, 3))  
plot(density(mu), xlab = "", main = "mu")  
plot(density(tau), xlab = "", main = "tau")  
image(MASS::kde2d(mu, tau), xlab = "mu", ylab = "tau")
```



- La inferencia basada en **simulación** permite hacer **inferencia** sobre funciones de los parámetros que **no hayamos simulado**.
- Si queremos hacer inferencia sobre $h(\theta, \phi)$ y hemos simulado sólo valores de $P(\theta, \phi \mid \mathbf{x})$, entonces $h(\theta_i, \phi_i)$ será una **muestra de ese estadístico**, que podremos utilizar para hacer inferencia sobre él.

Ejemplo

- En el caso del colesterol, si queremos hacer **inferencia sobre la varianza** en lugar de la precisión de los datos:

```
summary(1/tau)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  70.84  150.25  216.18  257.42  306.30 1415.83
```

- O si queremos estimar el **coeficiente de variación** (σ/μ) de los datos:

```
summary((tau^(-0.5))/mu)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.07457 0.10858 0.13022 0.13680 0.15501 0.33337
```