

# Motivación e introducción a las técnicas de simulación MCMC

Introducción a la inferencia bayesiana basada en simulación

Miguel Ángel Martínez Beneito  
miguel.a.martinez@uv.es



## Sección 1

### Inferencia bayesiana analítica

# Inferencia bayesiana analítica

- La **inferencia bayesiana**, dado un modelo estadístico, **actualiza la información** inicial que pudiéramos tener sobre sus parámetros con la información proporcionada por los **datos**.
- El mecanismo que lleva a cabo esa actualización es el **Teorema de Bayes**:

$$P(\theta \mid \mathbf{x}) = \frac{P(\mathbf{x}|\theta)P(\theta)}{P(\mathbf{x})} \propto P(\mathbf{x}|\theta)P(\theta)$$

- Como resultado se obtiene la distribución a **posteriori** ( $P(\theta \mid \mathbf{x})$ ) de los parámetros **a partir de** la función de **verosimilitud** ( $P(\mathbf{x}|\theta) = L(\theta)$ ) y su **distribución inicial** ( $P(\theta)$ ).

## Ejemplo

- Queremos estimar el **porcentaje** de personas enfermas de **COVID** en cierta región.

## Ejemplo

- Tomamos una **muestra** aleatoria de la población de **50 personas** en la que se observan **3 infectados**.

$$x \mid \pi \sim \text{binomial}(\pi, 50)$$

$$P(x = 3 \mid \pi) \propto \pi^3(1 - \pi)^{47}$$

- Queremos usar como **información inicial** que en otra oleada anterior de **20 pruebas** se observaron **2 positivos**.


$$\pi \sim \text{beta}(2, 18)$$

$$P(\pi) \propto \pi^{2-1}(1 - \pi)^{18-1}$$

- Aplicando el **teorema de Bayes** tenemos:

$$P(\pi \mid x = 3) \propto P(x = 3 \mid \pi)P(\pi) \propto \pi^{5-1}(1 - \pi)^{65-1}$$

$$\pi \mid x \sim \text{beta}(5, 65)$$



- El **mecanismo** de aprendizaje bayesiano es, en principio, **sencillo e intuitivo**.
- Desgraciadamente, basta con utilizar distribuciones iniciales **no conjugadas** para que **todo se complique** con facilidad.

## Ejemplo (Colesterol)

- Se pretende estimar el valor medio de **colesterol** en sangre en cierta población, y disponemos de una **muestra** de valores  $\{x_1, \dots, x_n\}$ .
- Dichos valores se distribuyen según una **distribución Normal** alrededor de su media ( $\mu$ ) y con precisión  $s^{-2}$  (conocida).

$$\begin{aligned} L(\mu) &= P(\{x_1, \dots, x_n\} \mid \mu, s^{-2}) = \prod_{i=1}^n P(x_i \mid \mu, s^{-2}) = \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi s^2}} \exp\left(\frac{-(x_i - \mu)^2}{2s^2}\right) = \dots \propto \exp\left(\frac{-(\mu - \bar{x})^2}{2s^2/n}\right) \end{aligned}$$

- Conocemos por distintos estudios que el valor de  $\mu$  en otras poblaciones toma valores **en torno a 100 y con varianza 20<sup>2</sup>**.
- Querríamos **incorporar dicha información** a nuestra estudio, pero **evitar** que la distribución inicial sea **demasiado influyente**.

## Ejemplo

- Decidimos asumir una **distribución t** (con colas muy pesadas) como previa para  $\mu$ :

$$\mu \sim t_1(\mu \mid 100, 20^2) \propto \left(1 + \frac{(\mu - 100)^2}{20^2}\right)^{-1}$$

- Aplicando el **teorema de Bayes**:

$$P(\mu \mid \mathbf{x}) = \frac{P(\mathbf{x} \mid \mu)P(\mu)}{P(\mathbf{x})} = \frac{\exp\left(\frac{-(\mu - \bar{x})^2}{2s^2/n}\right) \left(1 + \frac{(\mu - 100)^2}{20^2}\right)^{-1}}{P(\mathbf{x})}$$

donde

$$P(\mathbf{x}) = \int_{-\infty}^{\infty} \exp\left(\frac{-(\mu - \bar{x})^2}{2s^2/n}\right) \left(1 + \frac{(\mu - 100)^2}{20^2}\right)^{-1} d\mu = ???$$

- Por tanto, el cálculo de  $P(\mu \mid \mathbf{x})$  requiere el **cálculo** de una integral “**poco amigable**”.

- El uso de distribuciones **no conjugadas** conlleva el cálculo analítico de **integrales** para obtener el término  $P(\mathbf{x})$  del teorema de Bayes.
- La sustitución del cálculo de dicha integral por algún **procedimiento numérico** computacionalmente manejable sería de **gran utilidad**.
- Paralelamente, todo se puede **complicar**, incluso utilizando distribuciones **iniciales conjugadas**. Basta con plantearnos inferencia bayesiana en **modelos multiparamétricos** para que los cálculos analíticos se compliquen con facilidad.
- Resulta muy conveniente disponer de un mecanismo de **inferencia paralelo** que **obvie las dificultades** numéricas que presentan los modelos bayesianos, salvo aquellos extremadamente simples.



## Sección 2

### Inferencia bayesiana basada en simulación

# Motivación a la inferencia basada en simulación

- La **simulación** de muestras aleatorias supone una útil herramienta para la **inferencia** cuando el **abordaje analítico** resulta **demasiado complejo**.

## Ejemplo

- Un conocido, **director de un hospital** nos plantea la siguiente cuestión:
  - El número diario de **altas hospitalarias** se distribuye según  $A \sim \text{Bi}(a \mid 0.17, n)$ , donde  $n$  es el número de pacientes ingresados en el hospital.
  - El número medio diario de **ingresos hospitalarios** sigue una distribución de Poisson de media 50, i. e.  $I \sim \text{Po}(i \mid 50)$ .
- Actualmente, el hospital tiene **todas sus plazas** ( $n=300$ ) **ocupadas** y se nos plantea si mañana **serán capaces de atender todas las demandas** de ingreso, es decir, se quiere conocer la probabilidad de que el número de altas sea superior al número de ingresos.

## Ejemplo

- Si  $A$  denota el número de altas y  $I$  el número de ingresos el día siguiente, deberíamos **calcular**:

$$P(A \geq I) = \sum_{A=0}^{\infty} \sum_{I=0}^a \pi(i, a) = \sum_{a=0}^{\infty} \text{Bi}(a|0.17, 300) \left( \sum_{i=0}^a \text{Po}(i|50) \right)$$

- Esta suma **no tiene forma analítica**, por tanto  $P(A \geq I)$  tampoco la tiene.
- Así,  $P(A \geq I)$  **sólo** puede ser calculado **numéricamente**, por ejemplo con R.
- Alternativamente**, podríamos aproximar  $P(A \geq I)$ , fácilmente, **mediante simulación**:

```
set.seed(1)
A <- rbinom(10000, prob = 0.17, size = 300)  #Altas
I <- rpois(10000, 50)  #Ingresos
sum(I >= A)/10000
## [1] 0.4815
```

- En general, la **simulación** es una **estrategia** que deberíamos tener en cuenta cuando la **aproximación analítica** resulta **problemática**, también desde una perspectiva bayesiana.

## Inferencia basada en simulación:

- En general, si  $\theta \sim \pi(\theta)$ , para una función genérica  $h(\cdot)$  queremos estimar:

$$E_{\pi}[h(\theta)] = \int_{\Omega} h(\theta)\pi(\theta)d\theta \quad (1)$$

- Esta expresión incluye, como casos particulares, **todos los momentos** (media, varianza ...) de  $\theta$ .
- También  $h(\theta)$  podría ser una **función de verosimilitud** (y  $\pi(\theta)$  la distribución inicial de un parámetro  $\theta$ ), en cuyo caso la expresión (1) proporciona el **denominador** del **teorema de Bayes**.
- En general, la expresión (1) será **difícil** (o imposible) de calcular **analíticamente**.

- Los *métodos de integración de Monte Carlo* buscan **aproximar** la expresión (1) **mediante muestras** aleatorias de  $\theta$ .
- El **principio** de los métodos de integración de **Monte Carlo** para aproximar (1) es el siguiente:
  - Generar una muestra  $\boldsymbol{\theta} = \{\theta^{(1)}, \dots, \theta^{(M)}\}$  de  $\pi(\theta)$ .
  - Aproximar (1) por  $\overline{h_M(\boldsymbol{\theta})} = M^{-1} \sum_{m=1}^M h(\theta^{(m)})$ .
- Este resultado es consecuencia directa de la **Ley Fuerte de los Grandes Números**<sup>1</sup>.
- Además, asintóticamente, según el **Teorema Central del Límite**:

$$\overline{h_M(\boldsymbol{\theta})} \sim N(E_\pi[h(\theta)], \text{Var}(h(\theta))/M).$$

Así,  $\overline{h_M(\boldsymbol{\theta})}$  es **insesgado**, y podemos aproximar  $E_\pi[h(\theta)]$  con la **precisión deseada**, simplemente **incrementando el tamaño muestral** de  $\boldsymbol{\theta}$ .

---

<sup>1</sup>*Ley fuerte de los grandes números:* Si  $X_1, X_2, \dots$  es una muestra de valores aleatorios i.i.d. con  $E(X_i) = \mu$ , entonces  $\lim_{n \rightarrow \infty} \bar{X}_n = \mu$

## Ejemplo

- Volviendo al estudio de las **altas e ingresos** hospitalarios, queríamos estimar:

$$P(A \geq I) = \sum_{a=0}^{\infty} \sum_{i=0}^a \pi(i, a) = \sum_{(i,a) \in \Omega} \delta(a \geq i) \pi(i, a)$$

- De acuerdo con el método de integración (suma en este caso) de Monte Carlo esta última expresión **puede ser aproximada** por

$$M^{-1} \sum_{m=1}^M \delta(a^{(m)} \geq i^{(m)})$$

**para una muestra**  $\{(i^{(1)}, a^{(1)}), \dots, (i^{(M)}, a^{(M)})\}$  de  $\pi(i, a)$ .

- Este mismo proceso es el que **aplicamos**, de manera intuitiva, en el **ejemplo anterior**.

## Ejemplo

- Además, si así lo quisiéramos, también podríamos estimar el **cociente entre los ingresos y altas** para el día siguiente

$$E\left(\frac{I}{A}\right) = \sum_{(i,a) \in \Omega} \frac{i}{a} \pi(i, a)$$

aproximándolo mediante:


$$M^{-1} \sum_{m=1}^M \frac{i^{(m)}}{a^{(m)}}$$

que puede calcularse como:

```
mean(I/A)
```

```
## [1] 0.9984982
```

- También podemos utilizar la aproximación normal del **Teorema Central del Límite** para cuantificar la **variabilidad** de la aproximación de Monte Carlo.
- Para el caso de  $E(I/A)$ :





## Ejemplo

- Se podrían llevar a cabo **procedimientos similares** para estimar **otros parámetros** de interés:

- $E(I) \approx M^{-1} \sum_{m=1}^M i^{(m)} = \bar{i}$

```
mean(I)
```

```
## [1] 50.1087
```

- $Var(A) = E((A - E(A))^2) \approx M^{-1} \sum_{m=1}^M (a^{(m)} - \bar{a})^2 = Var(\mathbf{a})$

```
var(A)
```

```
## [1] 42.61239
```



- En general, **aproximaremos** cada cantidad de interés de una variable mediante el **estadístico muestral correspondiente** de la muestra (*método de los momentos*).
  - Media poblacional  $\rightarrow$  media muestral
  - Varianza poblacional  $\rightarrow$  varianza muestral
  - $P(0 < X < 0.5) \rightarrow$  proporción de veces que  $0 < X_i < 0.5$  en  $X_1, X_2, \dots$
  - ...

## Sección 3

### Markov chain Monte Carlo

# Simulación de Monte Carlo mediante cadenas de Markov

- Al hacer inferencia bayesiana nos encontramos en la **siguiente situación**:
  - Querremos muestrear** de la **distribución a posteriori** de una o varias variables.
  - La distribución a posteriori se conoce sólo parcialmente, se conoce su forma pero **no su constante de integración**.



- En caso de poder simular una **muestra** como la de la derecha nos permitiría **hacer inferencia** sobre el(/los) parámetro(s) deseado(s).

- Lamentablemente, las **distribuciones** de las que queremos muestrear serán **enrevesadas** y **problemáticas** para simular **valores independientes** de ellas.

## Cadenas de Markov:

- Una *cadena de Markov* es una **secuencia** ordenada de variables aleatorias  $\{x_1, x_2, \dots\}$  en los que cada valor, **condicionado a los anteriores**, depende **sólo** de la observación anterior. Es decir:

$$P(x_{i+1} \mid x_1, \dots, x_i) = P(x_{i+1} \mid x_i)$$

- El **futuro depende del pasado** sólo a través del **presente**.
- Se dice *distribución estacionaria* de una cadena de Markov la **distribución** que se reproduce al **simular indefinidamente** valores de la cadena.
- Una cadena de Markov **no es la muestra aleatoria que nos gustaría tener** de la correspondiente distribución estacionaria (son valores dependientes), pero **podría suplir** el uso de muestras independientes.

## Métodos de Monte Carlo basados en cadenas de Markov:

- Los *métodos de Monte Carlo basados en cadenas de Markov* (**MCMC** por sus siglas en inglés) son métodos basados en **simulación** en los que la **muestra** de valores generados es una **cadena de Markov**.
- El principal uso de las técnicas **MCMC** es la generación de **muestras** (markovianas) cuya distribución estacionaria coincide con la distribución **a posteriori** que queremos conocer (aunque desconozcamos su constante de proporcionalidad).
- **Objetivo:** simular una **cadena de Markov**  $\{\theta^{(1)}, \theta^{(2)}, \dots\}$  con **distribución estacionaria**  $P(\theta \mid \mathbf{x})$ , la **distribución a posteriori** de cierto modelo bayesiano.
- **Algoritmo** general:
  - Partimos de un **valor arbitrario**  $\theta^{(0)}$ .
  - Asumimos una **distribución**  $q(\cdot \mid \cdot)$  que permite simular  $\theta^{(i+1)} \mid \theta^{(i)} \sim q(\theta^{(i+1)} \mid \theta^{(i)})$  con **distribución estacionaria**  $P(\theta \mid \mathbf{x})$ .
  - **Simulamos** una **cadena de Markov** de la distribución anterior.

# Metropolis Hastings

- Es, junto a Gibbs Sampling, **el principal algoritmo** MCMC para el muestreo de distribuciones a posteriori.
- Se trata de un **algoritmo de aceptación/rechazo**.

*Algoritmo de simulación de Metropolis-Hastings:*

- 1 **Dado un valor  $\theta^{(i)}$**  de la cadena de Markov, **simulamos otro valor  $\theta^{(*)}$**  de una distribución  $q(\theta^{(*)} | \theta^{(i)})$  que nos sea conveniente
- 2 Calculamos la **probabilidad de aceptación** de  $\theta^{(*)}$ :

$$\alpha(\theta^{(*)}, \theta^{(i)}) = \min \left( 1, \frac{P(\theta^{(*)} | \mathbf{x}) q(\theta^{(i)} | \theta^{(*)})}{P(\theta^{(i)} | \mathbf{x}) q(\theta^{(*)} | \theta^{(i)})} \right)$$

- 3 Consideramos  $\theta^{(i+1)} = \begin{cases} \theta^{(*)} & \text{con probabilidad } \alpha \\ \theta^{(i)} & \text{con probabilidad } 1 - \alpha \end{cases}$
- 4 **Iterar** este procedimiento a conveniencia.

- Al tener  $\alpha$  dos posteriors  $P(\theta^{(*)} | \mathbf{x})$  y  $P(\theta^{(i)} | \mathbf{x})$ , en el numerador y el denominador, **no necesitamos su constante de integración** ya que cancelará.
- Este detalle es el que hace **útil** el algoritmo para **inferencia bayesiana**.
- **Cualquier distribución**  $q(\cdot | \cdot)$  es **válida** para el algoritmo, pero una **elección adecuada** hará que la cadena de Markov muestre **mejores propiedades** (mayor independencia).
- Un caso particularmente popular consiste en utilizar distribuciones **simétricas** para  $q(\cdot | \cdot)$ , es decir:

$$q(\theta^{(*)} | \theta^{(i)}) = q(\theta^{(i)} | \theta^{(*)}).$$

en ese caso el **cociente** del algoritmo se **simplifica**.

- De entre las propuestas simétricas, resulta particularmente **popular las caminatas aleatorias**, en las que las funciones de propuesta (simétricas) son del tipo:

$$q(\theta^{(*)} | \theta^{(i)}) = N(\theta^{(*)} | \theta^{(i)}, \tau^2),$$

o

$$q(\theta^{(*)} | \theta^{(i)}) = U(\theta^{(*)} | \theta^{(i)} - \delta, \theta^{(i)} + \delta).$$

donde  $\tau^2$  y  $\delta$  serán 2 **parámetros a sintonizar** y que influirán en la calidad final de la simulación.

## Ejemplo (Colesterol)

- Volviendo al ejemplo del **colesterol**. La **distribución a posteriori**, salvo constante de integración, era:

$$P(\mu | \mathbf{x}) \propto \exp\left(-\frac{(\mu - \bar{\mathbf{x}})^2}{2s^2/n}\right) \left(1 + \frac{(\mu - 100)^2}{20^2}\right)^{-1}$$



## Ejemplo


- Programamos un algoritmo de **Metropolis-Hastings de caminata aleatoria** para muestrear de  $\mu \mid \mathbf{x}$ , con función de propuesta  $q(\cdot \mid \cdot)$  **normal** de varianza  $2^2$ .

```
xbar <- 112.9
s2 <- 214.6
n <- 9
posterior <- function(mu) {
  exp(-((mu - xbar)^2)/(2 * s2/n)) * (1 + ((mu - 100)^2)/(20^2))^-1
}
}

muestra <- vector(length = 1000)
mu <- 100
set.seed(1)
```

## Ejemplo

```
for (i in 1:1000) {  
  munuevo <- rnorm(1, mu, 2)  
  alfa <- min(1, posterior(munuevo)/posterior(mu))  
  acepta <- rbinom(1, 1, alfa)  
  if (acepta == 1) {  
    mu <- munuevo  
  }  
  muestra[i] <- mu  
}
```



- La cadena generada muestra **dependencia**, pero nos permite **hacer inferencia** sobre  $\mu$ .

# Gibbs sampling

- El **problema de MH** es que si  $\theta$  es **multidimensional**, encontrar una **función de propuesta**  $q(\cdot | \cdot)$  razonable puede ser muy **complejo**.
- En ese caso, puede ser mucho mejor **muestrear, uno a uno**, los parámetros de  $\theta$ .
- Muestreo de *Gibbs Sampling* para  $P(\theta = (\theta_1, \dots, \theta_d) | \mathbf{x})$ :
  - **Inicializar**  $\theta^{(0)} = (\theta_1^{(0)}, \dots, \theta_d^{(0)})$ ;
  - Para  $i = 1, \dots, n$ .simulaciones:
    - **Simular**  $\theta_1^{(i)}$  de la distribución **condicional**  $\theta_1 | (\theta_2^{(i-1)}, \dots, \theta_d^{(i-1)}, \mathbf{x})$ ;
    - **Simular**  $\theta_2^{(i)}$  de la distribución **condicional**  $\theta_2 | (\theta_1^{(i)}, \theta_3^{(i-1)}, \dots, \theta_d^{(i-1)}, \mathbf{x})$ ;
    - ...
    - **Simular**  $\theta_d^{(i)}$  de la distribución **condicional**  $\theta_d | (\theta_1^{(i)}, \dots, \theta_{d-1}^{(i)}, \mathbf{x})$ ;
    - **Guardar**  $\theta^{(i)} = (\theta_1^{(i)}, \dots, \theta_d^{(i)})$  como elemento  $i$ -ésimo de la muestra a posteriori de  $P(\theta | \mathbf{x})$ .

- Habitualmente,  $\theta_j \mid \theta_1, \dots, \theta_{j-1}, \theta_{j+1}, \dots, \theta_d, \mathbf{x}$  suele ser **fácil de muestrear**, con alguna función de R.
- **Cuando no lo sea**, podremos emplear un algoritmo **MH** univariante para muestrear ese parámetro.

## Ejemplo

- Volviendo al ejemplo del **colesterol** nos planteamos ahora **modelizar** los datos de la siguiente manera<sup>a</sup>:

$$X_i \sim N(\mu, \tau), \quad i = 1, \dots, I$$

$$\mu \sim N(m, t), \quad \tau \sim \text{Gamma}(a, b)$$

con distribuciones iniciales **poco informativas**, por ejemplo con:  
 $m = 0, t = 10^{-6}, a = 0.001, b = 0.001$ .

- Querremos muestrear mediante **Gibbs Sampling** de la distribución conjunta de  $\mu, \tau$ .

---

<sup>a</sup>Las distribuciones normales en el modelo se han parametrizado en función de su precisión

## Ejemplo

- Función de **verosimilitud**:

$$L(\mu, \tau) = \prod_{i=1}^n P(x_i | \mu, \tau) \propto \tau^{n/2} \exp \left( \frac{-\tau \sum_{i=1}^n (X_i - \theta)^2}{2} \right)$$

- Distribución a **posteriori**:

$$P(\mu, \tau | \mathbf{x}) \propto \left( \tau^{n/2} \exp \left( \frac{-\tau \sum (X_i - \mu)^2}{2} \right) \right) \cdot \left( \exp \left( \frac{-t(\mu - m)^2}{2} \right) \right) \cdot (\tau^{a-1} \exp(-b\tau))$$

- Distribuciones **condicionales a posteriori**:

$$P(\mu | \mathbf{x}, \tau) \sim N \left( \frac{\tau \sum x_i + t \cdot m}{\tau \cdot n + t}, \tau \cdot n + t \right)$$

$$P(\tau | \mathbf{x}, \mu) \sim \text{Gamma} \left( a + \frac{n}{2}, b + \frac{\sum (x_i - \mu)^2}{2} \right)$$

## Ejemplo

- **Algoritmo de Gibbs** para el muestreo de  $P(\mu, \tau \mid \mathbf{x})$ :

```
x = c(106, 115, ...) # Datos: valores de colesterol
n = length(x) # n=9
m = 0; t = 1e-6; a = 0.001; b = 0.001 #hiperparámetros
mu = 100; tau = 1 # mu_0, tau_0
muestra <- matrix(nrow = 1000, ncol = 2)
for(i in 1:1000){
  # Muestreo de tau
  tau = rgamma(1, a + n/2, b + sum((x-mu)^2)/2)
  # Muestreo de mu
  mu = rnorm(1, (tau * sum(x) + t*m)/(tau * n + t),
            tau * n + t)
  muestra[i,] = c(mu, tau)
}
```


- Con este código **dispondremos de muestras** de  $P(\mu, \tau \mid \mathbf{x})$  que podremos utilizar a **nuestra conveniencia**.

# Ejemplo

```
summary(mu)  # Estadísticos de  $P(\mu/x)$ 
```

| ## | Min.  | 1st Qu. | Median | Mean  | 3rd Qu. | Max.  |
|----|-------|---------|--------|-------|---------|-------|
| ## | 112.7 | 112.9   | 112.9  | 112.9 | 112.9   | 113.1 |

```
par(mfrow = c(1, 3))  
plot(density(mu), xlab = "", main = "mu")  
plot(density(tau), xlab = "", main = "tau")  
image(MASS::kde2d(mu, tau), xlab = "mu", ylab = "tau")
```



- La inferencia basada en **simulación** permite hacer **inferencia** sobre funciones de los parámetros que **no hayamos simulado**.
- Si queremos hacer inferencia sobre  $h(\theta, \phi)$  y hemos simulado sólo valores de  $P(\theta, \phi \mid \mathbf{x})$ , entonces  $h(\theta_i, \phi_i)$  será una **muestra de ese estadístico**, que podremos utilizar para hacer inferencia sobre él.

## Ejemplo

- En el caso del colesterol, si queremos hacer **inferencia sobre la varianza** en lugar de la precisión de los datos:

```
summary(1/tau)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  70.84  150.25  216.18  257.42  306.30 1415.83
```

- O si queremos estimar el **coeficiente de variación** ( $\sigma/\mu$ ) de los datos:

```
summary((tau^(-0.5))/mu)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.07457 0.10858 0.13022 0.13680 0.15501 0.33337
```